

Strojno učenje – domaća zadaća 4

UNIZG FER, ak. god. 2016./2017.

Zadano: 31. 10. 2016. Rok: 4. 11. 2016.

Napomena: Zadatke možete rješavati samostalno ili u grupi. Ako zadatke rješavate u grupi, pobrinite se da svi članovi grupe pridonose rješenju i da ga naposlijetku svi razumiju. Po potrebi konzultirajte sve dostupne izvore informacija. Rješenja zadataka ponesite na iduće auditorne vježbe. Zabilježite sve nejasnoće i nedoumice, kako bismo ih prodiskutirali.

1. [Svrha: *Znati definirati model logističke regresije. Razumjeti izvod funkcije pogreške unakrsne entropije i pripadne funkcije gubitka. Shvatiti zašto je ta funkcija gubitka unakrsne entropije prikladna za klasifikaciju, dok funkcija kvadratnog gubitka to nije.*]
 - (a) Definirajte model logističke regresije. Zašto je sigmoidalna (logistička) funkcija prikladan odabir za aktivacijsku funkciju?
 - (b) Izvedite pogrešku unakrsne entropije $E(\mathbf{w}|\mathcal{D})$ kao negativnu log-izglednost na skupu označenih primjera.
 - (c) Napišite funkciju gubitka unakrsne entropije i nacrtajte njezin graf. Koliki je najveći a koliki najmanji mogući gubitak?
 - (d) Prepostavimo da su izlazne oznake $y \in \{-1, +1\}$ umjesto $y = \{0, 1\}$. Reformulirajte funkciju gubitka unakrsne entropije $L(h(\mathbf{x}), y)$ tako da koristi takve oznake te da vrijedi $L(0, y) = 1$ (kako bi funkcija bila kompatibilna s ostalim funkcijama gubitka koje smo radili).
 - (e) Nacrtajte graf funkcije gubitka $L(\mathbf{x}, y)$ u ovisnosti o udjelu pogrešne klasifikacije $y\mathbf{w}^T\mathbf{x}$, i to za: gubitak 0-1, kvadratni gubitak i logistički gubitak iz (d). Na temelju skice, odgovorite: (i) zašto je logistički gubitak dobar za klasifikaciju, a kvadratni gubitak to nije?; (ii) nanose li ispravno klasificirani primjeri ikakav gubitak?; (iii) možemo li reći da je logistički gubitak *konveksni surogat* gubitka 0-1, i što to znači?
2. [Svrha: *Prisjetiti se definicije konveksnosti funkcije. Razumjeti da konveksnost i unimodalnost nisu jedno te isto.*]
 - (a) Formalno definirajte kada je funkcija $f : \mathbb{R}^n \rightarrow \mathbb{R}$ konveksna.
 - (b) Funkcija f je *kvazikonveksna* (ili *unimodalna*) akko je njezina domena $\text{dom } f$ konveksna te ako za svaki $\mathbf{x}, \mathbf{y} \in \text{dom } f$ i $0 \leq \alpha \leq 1$ vrijedi

$$f(\alpha\mathbf{x} + (1 - \alpha)\mathbf{y}) \leq \max\{f(\mathbf{x}), f(\mathbf{y})\}.$$

Kvazikonveksnost je poopćenje konveksnosti: svaka je konveksna funkcija unimodalna, ali obrat ne vrijedi. Pokažite primjerom da obrat ne vrijedi.

- (c) Zašto u strojnog učenju volimo konkveksne funkcije pogreške? Koja je veza između konveksnosti funkcije pogreške i konveksnosti funkcije gubitka?
3. [Svrha: Razumjeti gradijentni spust i potrebu za linijskim pretraživanjem. Znati izvesti gradijentni spust za logističku regresiju. Demonstrirati upoznatost s prednostima i nedostatcima optimizacije drugog reda.]
- (a) Objasnite ideju gradijentnog spusta i potrebu za linijskim pretraživanjem.
 - (b) Objasnite razliku između grupnog (*batch*) i stohastičkog gradijentnog spusta. Koja je prednost ovog drugog?
 - (c) Izrazite gradijent funkcije pogreške unakrsne entropije $\nabla E(\mathbf{w}|\mathcal{D})$ i napišite pseudokod algoritma gradijentnog spusta (*batch* i stohastička izvedba).
 - (d) Opišite prednost i nedostatak optimizacije drugog reda (Newtonov postupak) u kontekstu logističke regresije.
4. [Svrha: Razumjeti kako regularizacija i linearna (ne)odvojivost utječe na gradijenti spust i na izgled funkcije pogreške u prostoru parametara.] Koristimo model L2-regularizirane logističke regresije učene algoritmom gradijentnog spusta. Iskušavamo dvije vrijednosti regularizacijskog faktora $\lambda = 0$ i $\lambda = 100$. Razmatramo posebno linearno odvojiv i linearno neodvojiv problem.
- (a) Skicirajte pogreške učenja i ispitivanja $E(\mathbf{w}|\mathcal{D})$ u ovisnosti o broju iteracija za $\lambda = 0$ i $\lambda = 100$ te za slučaj (i) linearno odvojivih i (ii) linearno neodvojivih primjera (dva grafikona sa po četiri krivulje).
 - (b) Načinite skice izokontura funkcije neregularizirane pogreške $E(\mathbf{w}|\mathcal{D})$ i L2-regularizacijskog izraza u ravnini w_1-w_2 . Napravite dvije odvojene skice: za linearno odvojive i linearno neodvojive primjere.
 - (c) Na grafikone iz prethodnoga zadatka dočrtajte izokonture L2-regulariziranih funkcija pogreške za $\lambda = 100$ i naznačite gdje se nalazi točka minimuma (w_1^*, w_2^*) . Gdje bi se nalazila točka minimuma za $\lambda = 0$?
5. [Svrha: Znati izvesti algoritam multinomijalne logističke regresije.]
- (a) Definirajte model multinomijalne logističke regresije.
 - (b) Izvedite pogrešku modela multinomijalne logističke regresije kao negativnu log-izglednost na skupu označenih primjera.
6. [Svrha: Uočiti zajedničkosti poopćenih linearnih modela.]
- (a) Opišite veze između (i) modela linearne regresije, logističke regresije i multinomijalne logističke regresije, (ii) distribucija zavisne varijable y i (iii) aktivacijskih funkcija f . Što je zajedničko svim distribucijama s kojima smo dosada radili?
 - (b) Objasnite riječima ovaj izraz:

$$\mathbf{w}^* = \operatorname{argmax}_w \ln P(\mathcal{D}|\mathbf{w}) = \operatorname{argmin}_w E(\mathbf{w}|\mathcal{D})$$

4) DOMAĆA ZADACĀ

1) a) DEF. MODEL LOG. REG. ZAŠTO JE SIGMOIDALNA FUNKCIJA PRIMJERNA KAO ODABIR ZA AKTIVACIJU?

DEF. MODELA LOG. REG.: $h(x) = g(\vec{w}^T \vec{x})$, gdje je $g(z) = \frac{1}{1+e^{-z}}$

$$h(x; w) = \frac{1}{1+e^{-w^T x}}$$

\Rightarrow Sigmoidalna funkcija je primjerica kao odabir za aktivacijsku funkciju zato što:

↳ Izlaz modela ima VEROJATNOSNU INTERPRETACIJU, jer predstavlja realne brojeve na intervalu $[0, 1]$.

↳ Izlaz modela je Bernoullijeva varijabla i njegova funkcija gubitka slabo kažnjava predobro klasificiranje primjere.

↳ Funkcija je DERIVABILNA $g' = g(1-g)$ (bitno za gradientni spust)

b) IZVOD ZA POGR. UNAKRSNE ENTROPIJE $E(\vec{w}|D)$ KAO NEG. LOG. IZGLEDNOST NA SKUPU OZNACENIH PR.

Funkcija pogreške = očekivajuća funkcija gubitka! Odnosno definirana je kao NEGATIVNA LOG. IZGLEDNOST NA SKUPU OZNACENIH PR.

$$\Rightarrow E(\vec{w}|D) = -\ln L(\vec{w}|D)$$

↳ S logističkom regresijom kolika je izglednost param. \vec{w} ? Želimo da ta izglednost bude stopeća.

$$\begin{aligned} \ln L(\vec{w}|D) &= \ln p(D|\vec{w}) = \ln \prod_{i=1}^N p(\vec{x}^{(i)}, y^{(i)} | \vec{w}) = \ln \prod_{i=1}^N p(y^{(i)} | \vec{x}^{(i)}, \vec{w}) p(\vec{x}^{(i)}) - \\ &= \sum_{i=1}^N \underbrace{\ln p(y^{(i)} | \vec{x}^{(i)}, \vec{w})}_{\text{konst. Ne ovisi o } \vec{w}} + \sum_{i=1}^N \underbrace{\ln p(\vec{x}^{(i)})}_{\text{konst. Ne ovisi o } \vec{w} = 0} \end{aligned}$$

↳ μ - vjerojatnost da je $y=1$

$y^{(i)}$ - BERNOULLIJEVA VARIJABLA O CINI 1, međusobno distribucija: $P(y^{(i)}) = \mu^{y^{(i)}} (1-\mu)^{1-y^{(i)}}$

Nas zanima $p(y^{(i)} | \vec{x}^{(i)}, \vec{w})$, odnosno $P(y^{(i)}=1 | \vec{x}^{(i)}, \vec{w})$ vjerojatnost da $x^{(i)}$ ima označku $y^{(i)}=1$:

$$\Rightarrow \mu = P(y^{(i)}=1 | \vec{x}^{(i)}, \vec{w}) = h(\vec{x}^{(i)}, \vec{w}) \Rightarrow P(y^{(i)} | \vec{x}^{(i)}, \vec{w}) = h(\vec{x}^{(i)}, \vec{w})^{\mu^{(i)}} (1-h(\vec{x}^{(i)}, \vec{w}))^{1-\mu^{(i)}}$$

$$\begin{aligned} \Rightarrow \ln L(\vec{w}|D) &= \sum_{i=1}^N \ln p(y^{(i)} | \vec{x}^{(i)}, \vec{w}) + \text{konst.} = \sum_{i=1}^N \ln \left(h(\vec{x}^{(i)}, \vec{w})^{\mu^{(i)}} (1-h(\vec{x}^{(i)}, \vec{w}))^{1-\mu^{(i)}} \right) = \\ &= \sum_{i=1}^N \left[\mu^{(i)} \ln h(\vec{x}^{(i)}, \vec{w}) + (1-\mu^{(i)}) \ln (1-h(\vec{x}^{(i)}, \vec{w})) \right] - \ln L(\vec{w}|D) \end{aligned}$$

$$\Rightarrow E(\vec{w}|D) = \sum_{i=1}^N \left(-y^{(i)} \ln h(\vec{x}^{(i)}, \vec{w}) - (1-y^{(i)}) \ln (1-h(\vec{x}^{(i)}, \vec{w})) \right)$$

↳ ALTERNATIVNO, KAKO POGR. NE BI OVISILA O BROJU PRIMJERA:

$$E(\vec{w}|D) = \frac{1}{N} \sum_{i=1}^N \left(-y^{(i)} \ln h(\vec{x}^{(i)}, \vec{w}) - (1-y^{(i)}) \ln (1-h(\vec{x}^{(i)}, \vec{w})) \right)$$

c) NAPISI FUNKCIJU GUBITKA UNAKRSNE ENTROPIJE I NACRTAJTE YUZAN GRAF.
KOLIKI JE NAGUECI, A KOLIKI NAGMANJI GUBITAK?


$$L(h(x), y) = -y \ln h(x) - (1-y) \ln(1-h(x)) \Rightarrow$$

↳ Izraz kompaktno definira granice za dva slučaja ($y=1$ i $y=0$)
(sam!) tjedno

↳ Gubitak neva kada je pr. savršeno klasificiran
↓

U svim drugim slučajevima postoji GUBITAK!

S grafom možemo vidjeti da začinjava se
pri ispravno klasificiranju, mali je na
ispravnoj strani granice, postoji malen gubitak
kada je pogrešno klasificirano.




• AKO JE PR. KLASIF. KAO $h=0$
ZA $y=0 \rightarrow$ Mali gubitak
• AKO JE PR. KLASIF. KAO $h=1$
ZA $y=1 \rightarrow$ Veliki gubitak!

d) $y \in \{-1, 1\}$ umesto $\{0, 1\}$. Reformulirajte $L(h(x), y)$ da koristi oznake i da veže s $L(0, y) = 1$

$$L(h(x), y) = \frac{1}{2 \ln 2} \ln(1 + e^{-y \bar{w}^T \bar{x}})$$

e) NACRTAJ GRAF FC GUBITKA $L(x, y)$ ZA $0-1$, KUADRATNI I LOGISTICKI GUBITAK.

i) ZATO JE LOGISTICKI GUBITAK DOBAR ZA KLASIFICIRJU A KUADRATNI GUBITAK NIJE?
- Zato što logistički gubitak puno manje kaznjava točno klasific. primjere.



ii) NAOSE LI ISPRAVNO KLASIFICIRANI PR. GUB.?
- Da, naroč. Ali kao što vidimo na grafu, gubitak je zanemarivo male u odnosu na krivo klasificirane primjere.

iii) MOŽEMO LI RECI DA JE LOG. GUB. KONVEKSNA?
PURSAT GUBITKA $0-1$ IZ TO INACI?
- Da možemo. To znači da ona za svaki $y \bar{w}^T \bar{x}$ prolazi (ZNAJ) funkciju gubitka $0-1$, odnosno kažemo da je ona njezina KONVEKSNA GORNJA MEĐA!

2) a) FORMALNO DEF. KADA JE $f: \mathbb{R}^n \rightarrow \mathbb{R}$ KONVEKSNA!

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ je konveksna \Leftrightarrow ① je neznačaj dom(f) KONVEKSAN STUP.

② za $\forall x_1, x_2 \in \text{dom}(f)$ i $\forall \lambda \in (0, 1)$ vrijedi:


$$f(x) = f(\lambda x_1 + (1-\lambda)x_2) \leq \lambda f(x_1) + (1-\lambda)f(x_2)$$

b) f je KVAZIKONVEKSNA (unimodala) \Leftrightarrow je $\text{dom}(f)$ CUX te ako za

$\forall x_1 \in \text{dom}(f) \quad \forall \alpha \in (0,1) \quad \forall y \quad f(\alpha x_1 + (1-\alpha)y) \leq \max\{f(x_1), f(y)\}$

KVAZIKONVEKSNE JE POČEĆENJE KONVEKSNOŠĆI: Sviha f CUX f je unimodala, ali obrat ne vrijedi! \rightarrow Dokazati primjerom

npr. $f(x) = \sqrt[3]{x^2}$



$$x_1 = 1, x_2 = 2, \alpha = 0.5$$

i) KONVEKSNA? $f(\alpha x_1 + (1-\alpha)x_2) \leq \alpha f(x_1) + (1-\alpha)f(x_2)$

$$f(0.5x_1 + 0.5x_2) \leq 0.5f(x_1) + 0.5f(x_2)$$

$$f(1.5) \leq 0.5f(1) + 0.5f(2)$$

$$1.31 \leq 0.5 + 0.79 = 1.29$$

$$1.31 \leq 1.29 \quad \underline{\text{NE}} \quad f \text{ NIJE CUX}$$

ii) KVAZIKONVEKSNA? $f(\alpha x_1 + (1-\alpha)x_2) \leq \max\{f(x_1), f(x_2)\}$

$$1.31 \leq \max(1, 1.59) = 1.59 \quad \underline{\text{DA}} \quad f \text{ je KVAZIKONVEKSNA}$$

c) ZAŠTO U SVU VOLITU KONVEKSE FJE POGREŠKE? KAJA JE UZETI MEĐU KONVEKSNOŠĆI FJE POGR. I KONVEKSNOŠĆI FJE GUBITKA?

Svojstvo konveksnosti je potrebno jer garantira da će se rešenjem problema dobiti GLOBALNI, a ne LOKALALNI MINIMUM! \rightarrow Konveksne fje imaju jedan globalni minimum!

Funkcija počesu = $\sum f_i$ gubitka. Stoga, ako je SVAKA pojedinačna fja konveksna, tada je i zbroj tih fja konveksan. Odmorpho, tada je i fja počeske konveksna fja!

3) a) KAJA JE IDEJA GRAD. SPUSTA I LINIJSKOG PRETRAŽIVANJA?

GRADJENTNI SPUST je jednostavan postupak heuristike optimizacije.

Gradijentni spust zasnuje se na ideji da za funkciju $f(x)$ u točci $x^{(t)}$ nevaže vjedni $\nabla f(x) = 0$, dok u ostalim točkama funkcije vrijednost gradijenta $\nabla f(x)$ odgovara smjeru PORASTA FUNKCIJE.

LINIJSKO PRETRAŽIVANJE - potrebnoum je s obzirom da ne možemo analitički odrediti grad. fje poč. kvalitativne euklipske.
↳ odabire se 12 točki minimizira $f(x)$ u svijetu spusta.

IDEJA: Kreće se od neke pozeti točke x , minimum fje pronađati se ažuriranjem vrijednosti x u svijetu koji je suprotan vektor ∇f , dokle god se ∇f ne izjednači s 0! Ako je fja konveksna, pronađeni minimum je globalni minimum.

b) OBJASNI RAZLIKU IMEĐU GRUPNOG (batch) I STOHASTICKOG GRAD. SPUSTA
KAJA JE PREDNOST STOHASTICKOG?

GRUPNI (batch): - Računa ukupan $\nabla E(w)$ za sve primere iz skupa za učenje
STO. SPUST

STOHASTICKI: - Ugastanje težina obavlja se na temelju svakog primjera pojedinačno, a to se onda ponavlja za svaki primjer iz skupa za učenje.

> PREDNOST: - MANJE RAČUNAVANJE ZAHTEVAN I MANJE PODUŽAN
ZAGLAVLJAVANJE U LOKALNOJ OPTIMIZACIJI, jedan minimum, Kod fja koje nisu konveksne.
- Pogodan za on-line učenje

C) IZRAZI GRAD. FN. POG.R. UNAKRSNE ENERGIJE $E(\tilde{w}|D)$ I NAPISI PSEUDOKOD
ALG. GRAD. SPUSTA (batch; on-line)

$$E(\tilde{w}|D) = \sum_{i=1}^n (h(\tilde{x}^{(i)}) - y^{(i)}) \tilde{x}^{(i)}$$

BATCH

$$\tilde{w} = (0, 0, 0, \dots, 0)$$

PONAVLJANJE DO KONVERGENCIJE

$$\Delta \tilde{w} = (0, 0, 0, \dots, 0)$$

ZA $i = 1, \dots, N$

$$h = g(\tilde{w}^T \tilde{x}^{(i)})$$

$$\Delta \tilde{w} = \Delta \tilde{w} + (h - y^{(i)}) \tilde{x}^{(i)}$$

$$\tilde{w} = \tilde{w} - \eta \cdot \Delta \tilde{w}$$

STOP

$$\tilde{w} = (0, 0, 0, \dots, 0)$$

PONAVLJANJE DO KONVERGENCIJE

SUČ. PERMUTACIJA PR. UD.

ZA $i = 1, \dots, N$

$$h = g(\tilde{w}^T \tilde{x}^{(i)})$$

$$\tilde{w} = \tilde{w} - \eta \cdot (h - y^{(i)}) \tilde{x}^{(i)}$$


d) PREDNOST / NEDOSTATCI OPTIMIZACIJE II RODA (NEWTON) U KONTekSTU LOGISTIKE REGRESIJE?

PREDNOSTI: MANJE ITERACIJE \rightarrow BRŽI PRONAĐAVANJE MINIMA

NEDOSTATCI: RAČUNSKA ZAHTEVNOST \rightarrow PROBLEM JE PRORAČUN HESSIAN MatriCE U SVAKOM KORAKU

L2-reg učen. ALG. GRAD. SPUSTA. $\lambda = 0$ i $\lambda = 100$. RAZM. UN ODV. I NEODV. PROBLem $n, \lambda = 0 \text{ i } 100$

a) POG.R. UC. I ISPOVJEDA $E(\tilde{w}|D)$ U OVISNOSTI O BR. ITERACIJA. i) UN ODV. ii) NE ODV.




za $\lambda = 0$, nema regularizacije, lin odgovori
primjeni standardni $E(\tilde{w}|D)$, GRADIENT
POGREŠKE U DOD. SUČ. NEKADA NEĆE
BIT JEDNAK 0 (fia početke neka min),
GRAD SPUST NEĆE KONVERGIRATI,
TEINE RASTU UAS. (SLOVENSKI MODEL)

$\lambda = 100$ učimo REGULARIZACIJU kojom
KAJNUJAMO SLOTENE MODELE I VECI λ ,
VEĆA KADAM SLOTENIH MODELIMA SRPČAVAJU
SE PREVAUCENOST, DOVADU DO STAGNACIJE U
IZNOBU POGREŠKE.


C) (w_1^*, w_2^*)

b) SKICE IZOKONTURA FZ. NEREG. POG.R. $E(\tilde{w}|D)$ I L2 REG. IZRAZA U w_1-w_2 RAVNINI

$\lambda = 0$ LIN.
ODVOGLIVI
 $\lambda = 100$ PR.



bez reg.
 $\lambda = 0$
 (w_1^*, w_2^*)



OVAJ MORAĆA ZA LINEARNO REGULARIZACIJE PRIMJERI, NIKADA NEĆEMO PRENAĆU N!! Zato što
će vitiči biti nečeli potreba klasifikacija
primjera s obzirom da je nemotivisani linearne
odgovor. Izlog razloga i za $\lambda = 0$ i za
 $\lambda = 100$ dolazi do stagnacije našim
određenog broja iteracija. Za $\lambda = 100$ greška je
manja jer se reguliranjem kajnujući
stvari modeli.

5) DEF. MODEL MULTINOMIJALNE LOGISTIČKE REGRESIJE → MNR

$$h_k(\vec{x} | \vec{w}) = \frac{\exp(\vec{w}_k^T \Phi(\vec{x}))}{\sum_j \exp(\vec{w}_j^T \Phi(\vec{x}))} = P(y=j | \vec{x}, \vec{w}) \rightarrow w = (w_1, \dots, w_K)$$

b) izvod početke MNR modela kao neg. log izrac. na skupu obućac. pr.

$$E(\vec{w}|D) = -\ln L(\vec{w}|D) = -(\ln P(D|w)) = -(\ln \prod_{i=1}^N P(y_i|x_i))$$

$$\text{uz } y = (y_1, y_2, \dots, y_N)^T \text{ s } P(y|\mu) = \prod_{k=1}^K \mu_k^{y_k}$$

$$E(\vec{w}|D) = -\ln \prod_{i=1}^N \prod_{k=1}^K \mu_k^{y_k^{(i)}} = -\ln \prod_{i=1}^N \prod_{k=1}^K h_k(x_i^{(i)} | w_k) = -\sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln h_k(x_i^{(i)} | w_k)$$

$$\Rightarrow E(\vec{w}|D) = -\sum_{i=1}^N \sum_{k=1}^K y_k^{(i)} \ln h_k(\vec{x}^{(i)} | \vec{w})$$

6) OBJASNJUJTE ZAŠTO:

i) MODELA LINEARNE REGRESIJE, LOGISTIČKE REGRESIJE I MULTINOMIJALNE LOG. REG.:

$h(x; w) = f(w^T \Phi(x))$	$\xrightarrow{\text{LINEAR.}}$	$f = x \rightarrow h_1 = w^T x$	$\xrightarrow{\text{SUM 3 SU POČETNI LINIČARI MODELI?}}$
	$\xrightarrow{\text{LOG. REG}}$	$f = g(x) \rightarrow h_2 = 1 / 1 + \exp(-w^T \Phi(x))$	
	$\xrightarrow{\text{MNR}}$	$f = \text{SOFTMAX} \rightarrow h_3 = \frac{\exp(w^T \Phi(x))}{\sum_j \exp(w_j^T \Phi(x))}$	

iii) AKTIVAC. FUNK.

ii) DISTRIBUCIJA ZAVISNE VAR. y :

$$\xrightarrow{\text{LINEAR. REG.}} : P(y|x, w) = \mathcal{N}(h(x), \sigma^2) \quad - \text{NORMALNA DISTRIB.}$$

$$\xrightarrow{\text{LOG. REG.}} : P(y|x, w) = h(x)^y (1-h(x))^{1-y} \quad - \text{BERNOULLIJEVA DISTRIBUC.}$$

$$\xrightarrow{\text{MNR}} : P(y|x, w) = \prod_{k=1}^K h_k(x)^{y_k} \quad - \text{MULTINOMIJALNA DISTRIBUC.}$$

b) OBJASNJUJTE OVAJ IZRAZ:

$$\vec{w}^* = \underset{w}{\operatorname{argmax}} \ln P(D|\vec{w}) = \underset{w}{\operatorname{argmin}} E(\vec{w}|D)$$

$\xrightarrow{\text{OPTIMALNI PARAM.}}$ $\xrightarrow{\text{MAKSIMIZACIJA LOG. PREGEDOSTI}}$ $\xrightarrow{\text{MINIMIZACIJA POGREŠKE MODELA}}$

→ Minimizacija pogreške modela odgovara maksimizaciji log. izglednosti na skupu obućenih primjera. Odnosno:

→ OPTIMALNI PARAMETRI \vec{w}^* MAKSIMIZIRAJU LOG. IZGLEDOST, ODNOŠNO MINIMIZIRAJU POGREŠKU!!