

Strojno učenje – domaća zadaća 6

UNIZG FER, ak. god. 2016./2017.

Zadano: 15. 11. 2016. Rok: 18. 11. 2016.

Napomena: Zadatke možete rješavati samostalno ili u grupi. Ako zadatke rješavate u grupi, pobrinite se da svi članovi grupe pridonose rješenju i da ga naposlijetku svi razumiju. Po potrebi konzultirajte sve dostupne izvore informacija. Rješenja zadataka ponesite na iduće auditorne vježbe. Zabilježite sve nejasnoće i nedoumice, kako bismo ih prodiskutirali.

1. [Svrha: *Znati definirati osnovne jezgrene funkcije. Znati definirati jezgreni stroj i razumjeti razliku između jezgrenog stroja i rijetkog jezgrenog stroja.*]
 - (a) Definirajte jezgenu funkciju, RBF-jezgru i Gaussovnu jezgru.
 - (b) Definirajte Mahalanobisovu udaljenost i RBF-jezgru koja koristi tu udaljenost. Navedite primjer u kojem biste koristili tu jezgru umjesto Gaussove jezgre.
 - (c) Definirajte jezgrenti stroj i rijetki jezgrenti (vektorski) stroj. Koji od njih je parametarski a koji neparametarski algoritam i što to znači?
2. [Svrha: *Isprobati preslikavanje primjera u prostor značajki primjenom Gausso-vih baznih funkcija. Razumjeti kako preslikavanje utječe na broj parametara i hiperparametara modela.*] Raspolažemo skupom primjera:

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^5 = \{((-1, -1), 0), ((0, 0), 0), ((3, -3), 1), ((-2, 1), 1), ((-4, 2), 1)\}.$$

- (a) U ulaznom prostoru skicirajte diskriminacijsku granicu $h(\mathbf{x}) = 0$ koju biste dobili logističkom regresijom uz $\phi(\mathbf{x}) = (1, \mathbf{x})$, tj. bez preslikavanja (izračun nije potreban).
- (b) Na isti skup primjera primijenite jezgrenti stroj s baznim funkcijama:

$$\phi_j(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \boldsymbol{\mu}_j\|^2}{2\sigma_j^2}\right).$$

Konkretno, koristite dvije bazne funkcije s parametrima $\boldsymbol{\mu}_1 = (0, 0)$, $\boldsymbol{\mu}_2 = (-3, 3)$, $\sigma_1 = \sigma_2 = 1$. Skicirajte primjere u prostoru značajki (dimenzije ϕ_1 i ϕ_2) i granicu koju biste dobili linearnom regresijom (izračun nije potreban).

- (c) Koliko ovaj jezgrenti stroj ima parametara a koliko hiperparametara? Kako biste u praksi odredili vrijednosti hiperparametara modela? Utječu li u ovom slučaju hiperparametri na složenost modela? Obrazložite odgovor.

3. [Svrha: *Razumjeti jezgrenti trik kod SVM-a.*]

- (a) Koristimo polinomijalnu jezgrentu funkciju $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^2$. Pokažite da je za $n = 2$ jezgra κ Mercerova jezgra. Zašto je to bitno?

- (b) Odredite vektor $\phi(\mathbf{x})$ u koji će efektivno biti preslikan primjer $\mathbf{x} = (2, 3)$ pri-mjenom jezgre $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^2$.
- (c) Veza između primarnih i dualnih parametara SVM-a jest $\mathbf{w} = \sum_{i=1}^N \alpha_i y^{(i)} \phi(\mathbf{x}^{(i)})$. Na skupu za učenje trenirali smo SVM s polinomijalnom jezgrenom funkcijom, $\kappa(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + 1)^3$. Potporni vektori su $\mathbf{x}^{(1)} = (-2, 3, 5)$, $\mathbf{x}^{(2)} = (6, 4, 3)$ i $\mathbf{x}^{(3)} = (8, 8, 2)$. Prvi primjer je negativan, a druga dva su pozitivna. Lagrange-ovi koeficijenti su $\alpha_1 = 0.131$, $\alpha_2 = 0.048$ i $\alpha_3 = 0.013$. Pomak je $w_0 = -0.51$. Iskoristite jezgrevi trik te odredite klasifikaciju primjera $\mathbf{x}^{(4)} = (1, 2, 3)$.

4. [Svrha: Razumjeti karakteristike Gaussove jezgre.]

- (a) Primjenom operacija za izgradnju složenijih Mercerovih jezgri iz jednostavnijih Mercerovih jezgri, dokažite da je Gaussova jezgra Mercerova jezgra. (Pomoć: raspišite izraz $\|\mathbf{x} - \mathbf{x}'\|^2$.)
- (b) Kako parametar $\gamma = 1$ Gaussove jezgre utječe na složenost modela? Koji je odnos između parametra C i γ ?
- (c) Koristimo Gaussovou jezgru uz $\gamma = 1$. Možemo li u ovom slučaju odrediti u koji vektor $\phi(\mathbf{x})$ u prostoru značajki će biti preslikan primjer \mathbf{x} ? Možemo li odrediti težine \mathbf{w} . Zašto?
- (d) Jamči li primjena Gaussove jezgre (1) empirijsku pogrešku jednaku nuli na skupu za učenje? (2) savršenu linearnu odvojivost primjera za učenje u prostoru značajki? (3) minimalnu pogrešku na ispitnom skupu? (4) preslikavanje primjera u beskonačan prostor značajki?

5. [Svrha: Isprobati klasifikator k-nn na konkretnom primjeru. Razumjeti kako parametri k i broj primjera N utječu na složenost modela.]

- (a) Klasifikator 4-NN s euklidskom udaljenošću učen je na sljedećim primjerima iz $\mathbb{R}^3 \times \{0, 1\}$:

$$\mathcal{D} = \{((\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^6 = \{((4, 4, 0), 1), ((4, 3, 1), 1), ((6, 0, 2), 1), ((5, 2, 2), 0), ((5, 1, 1), 0), ((7, 2, 0), 0)\}.$$

Odredite klasifikaciju primjera $\mathbf{x}^{(1)} = (4, 2, 1)$ i $\mathbf{x}^{(2)} = (0, 3, 3)$.

- (b) Ponovite klasifikaciju s težinskim modelom 4-NN, primjenom inverzne kvadratne jezgre.
- (c) Skicirajte (za općenit slučaj) pogrešku učenja i pogrešku generalizacije kao funkciju od k .
- (d) Skicirajte (za općenit slučaj) pogrešku učenja i pogrešku generalizacije kao funkciju broja primjera N za $k = 1$ i $k = 3$ (nacrtajte dva zasebna grafikona).

6. [Svrha: Shvatiti uzročne veze između nevezanih veličina.] Obrazložite u kakvim su odnosima sljedeći pojmovi: (a) složenost modela, (b) broj parametara modela, (c) dimenzija ulaznog prostora n i (d) broj primjera N . Analizirajte odnose između svih parova pojmoveva, posebno za parametarske, a posebno za neparametarske metode.

⑥ DOMAĆA ZADACΑ

a)

1) DEF. JEZGREN FV, RBF - regru i GAUSSOVU JEZGRU

- JEZGREN FV : $\mathcal{K} : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$
- RBF - jezgra : $\mathcal{K}(x, x') = \Phi(\|x - x'\|)$
- GAUSSOV JEZGRA : $\mathcal{K}(x, x') = \exp(-\gamma \|x - x'\|^2)$ gde je $\gamma = 1/\sigma^2$ PRECINOST

b) DEF. MATAJANOBISOVU UDALJENOST I RBF JEZGRU KOPA KORISTI TU UZAY. NAVEDI PR. KADA BI TU JEZGRU KORISTIO UMETNOGA GAUSSOVA.

$$D_{\text{MAX}} = \sqrt{(x - x')^T \Sigma^{-1} (x - x')}$$

$$\mathcal{K}(x, x') = \exp\left(-\frac{1}{2} (x - x')^T \Sigma^{-1} (x - x')\right)$$

↳ Σ - KOJARIJANCIJSKA MATRICA ZNACAKA

RBF regresija s Mahalanobisovom udaljenosću bolje je koristi od Gaussove jer je u slučaju kada:

- Kada su znaci različiti redova veličine ili različite jedinice
- Kada imamo visoku korelaciju između nekih znacaka.

c) DEF. JEZGRENI STROJ I RJEŠAK JEZGRENJI SIROJ. KOG OD NJIH JE PARAM. A KOJ NEPARAM. SLODOVITI?

→ PARAMETARSKI ALG. su algoritmi kod kojih BROJ PARAM. N NE OVISI O BROJ PRIMERA N!

→ NEPARAMETARSKI ALG. su algor. kod kojih BROJ PARAM. OVISI O BROJ PR.

→ JEZGRENI STROJ - Pojedini linearni model s preslikavanjem Φ kojeg brane sve Φ_j konz. jezgrena funkcije:

$$\Phi(x) = (\mathcal{K}(x, \mu_1), \mathcal{K}(x, \mu_2), \dots, \mathcal{K}(x, \mu_m))$$

gdje su μ_j - centroidi u prostoru primera.

→ RJEŠAK JEZGRENJI SIROVI - mjesto centroida kojeg primjeri za učenje

$$\Phi(x) = (\mathcal{K}(x, x_1), \mathcal{K}(x, x_2), \dots, \mathcal{K}(x, x_N))$$


↳ Pravjeravaju slijedost ispitnog p. s pr. za učenje

→ Iz prethodnih jednadžbi možemo primjetiti kako Rješak jezgreni sirovi ovise o broju primera N! Dok jezgreni sirovi ne ovise o N.

↳ Iz tog zaključujemo kako jezgreni sirovi padaju pod PARAMETARSKE ALG., dok rješak jezgreni sirovi pod NEPARAMETARSKE ALG.

$$2) D = \{(x^{(i)}, y^{(i)})\}_{i=1}^5 = \{((-1, -1), 0), ((0, 0), 0), ((3, -3), 1), ((-2, 1), 1), ((-4, 2), 1)\}$$

a) UML. PROSTORU S KIC. DISCRIM. GRANICA L(x) \Rightarrow KOPU BI DO BILU KOG. REG.
 $u \in \Phi(x) = \{1, x\}$ (BET PRESLUKAVANJA)



b) NA ISTI SCUP PRIMENI, $\Phi_1 = \exp\left(-\frac{\|x - \mu_1\|^2}{2\sigma_1^2}\right)$, $\mu_1 = (0, 0)$, $\mu_2 = (3, -3)$
 $\sigma_1 = \sigma_2 = 1$

$$\Phi_1 = \exp\left(-\frac{1}{2} \|x - [0] \|^2\right)$$

$$\begin{aligned}\Phi_1(x_1) &= e^{-1} \\ \Phi_1(x_2) &= e^0 = 1 \\ \Phi_1(x_3) &= e^{-9} \\ \Phi_1(x_4) &= e^{-5/2} \\ \Phi_1(x_5) &= e^{-1/2}\end{aligned}$$

$$\Phi_2 = \exp\left(-\frac{1}{2} \|x - [-\frac{3}{2}] \|^2\right)$$

$$\begin{aligned}\Phi_2(x_1) &= e^{-10} \\ \Phi_2(x_2) &= e^{-9} \\ \Phi_2(x_3) &= e^{-32} \\ \Phi_2(x_4) &= e^{-5/2} \\ \Phi_2(x_5) &= e^{-1}\end{aligned}$$


$$\begin{aligned}x_1 &= (e^{-1}, e^{-10}) \quad (0) \\ x_2 &= (e^0, e^{-9}) \quad (0) \\ x_3 &= (e^{-3}, e^{-32}) \quad (1) \\ x_4 &= (e^{-5/2}, e^{-5/2}) \quad (1) \\ x_5 &= (e^{-1/2}, e^{-1}) \quad (1)\end{aligned}$$

L
L
L
L
L
 $\Delta = 1$

c) $W = ?$ Hiperpara? Upravn ooredwanje
 VR. IMPERPARA? Ujednu u u svim
 svim IMPERPARA NA SLOZ. MODELA?

$$W = 3 \Rightarrow (W_0, W_1, W_2)$$

$$\begin{aligned}H_{ip} = 6 &\rightarrow \mu_1 = (\mu_{11}, \mu_{12}) \rightarrow 2 \\ \mu_2 = (\mu_{21}, \mu_{22}) &\rightarrow 2 \\ \sigma_1 = \sigma_2 &\rightarrow 2\end{aligned}$$



◦ Unakosnom prostoru

◦ μ re, ali θ da. $\theta = 1/\rho \rightarrow \theta \uparrow \rightarrow \rho \downarrow$

3) a) $JK(\vec{x}, \vec{z}) = (\vec{x} + \vec{z} + 1)^2 \rightarrow$ Polinomijalna jednica ka
 pokazi da je za $n=2$ JK MEREROVA JEDNICA. Zasto je to bitno?

$$\begin{aligned}JK(\vec{x}, \vec{z}) &= (\vec{x} + \vec{z} + 1)^2 = (x_1 z_1 + x_2 z_2 + 1)^2 = (x_1 z_1 + x_2 z_2 + 1)(x_1 z_1 + x_2 z_2 + 1) = \\ &= (x_1 z_1)^2 + x_1 x_2 z_1 z_2 + x_1 z_1 + x_1 x_2 z_2 + (x_2 z_2)^2 + x_2 z_2 + x_1 z_1 + x_2 z_2 + 1 = \\ &= (x_1 z_1)^2 + (x_2 z_2)^2 + 1 + 2x_1 z_1 x_2 z_2 + 2x_1 z_1 + 2x_2 z_2 = \\ &= (x_1 z_1)^2 + (x_2 z_2)^2 + 1 + \sqrt{2}x_1 z_1 \sqrt{2}x_2 z_2 + \sqrt{2}x_1 z_1 + \sqrt{2}x_2 z_2 = \\ &= (x_1^2, x_2^2, 1, \sqrt{2}x_1 z_1, \sqrt{2}x_2 z_2)^T (1, 1, \sqrt{2}z_1 z_2, \sqrt{2}z_1, \sqrt{2}z_2) \\ &= \Phi(x)^T \Phi(z)\end{aligned}$$

JK(x, z) ODGOVARA SKALARNOM MNOSTVU U PROSTORU
 ZNACAJKA 'S' TO POUCAJ DA JE JK(x, z) MEREROVA JEDNICA;
 $JK(x, z) = \Phi(x)^T \Phi(z)$. TO JE BINGO IZ RAZLOGA 'S' TO JE GREN I NEIK
 KOD SUM-A NECE FUNKCIONIRATI AKO JK(x, z) NJE MEREROVA
 JEDNICA.

b) $\Phi(x) = ?$ u koj je efektivno bit pre sustav $x = (2, 3)$ primjenom
jezgri $\Phi(x, z) = (x^T z + 1)^2$

$$\Phi(x) = (x_1^2, x_2^2, 1, \sqrt{2}x_1x_2, \sqrt{2}x_1, \sqrt{2}x_2) = (4, 9, 1, 6\sqrt{2}, 2\sqrt{2}, 3\sqrt{2})$$

c) $\vec{w} = \sum_{i=1}^n \lambda_i y^{(i)} \Phi(x^{(i)})$; $\vec{x} = (x^T z + 1)^3$

POP. VECT. $\rightarrow x^{(1)} = (-2, 3, 5)$ $x^{(2)} = (6, 4, 3)$ $x^{(3)} = (8, 8, 2)$ $y = (-1, 1, 1)$
 $\lambda_1 = 0.131$ $\lambda_2 = 0.048$, $\lambda_3 = 0.013$ $w_0 = -0.51$
KUADRATIČNI PRK. $x^{(4)} = (1, 2, 3) = ?$

$$f(x) = \vec{w}^T \Phi(x) + w_0 = \sum_{i=1}^n \lambda_i y^{(i)} \underbrace{\Phi^T(x^{(i)}) \Phi(x)}_{K(x, x^{(i)})} + w_0 = \sum_{i=1}^n \lambda_i y^{(i)} K(x, x^{(i)}) + w_0$$

$$\begin{aligned} f(x^{(4)}) &= \lambda_1 y^{(1)} K(x^{(4)}, x^{(1)}) + \lambda_2 y^{(2)} K(x^{(4)}, x^{(2)}) + \lambda_3 y^{(3)} K(x^{(4)}, x^{(3)}) + w_0 \\ &= -(0.131)(8000) + (0.048)(13824) + (0.013)(2979) - 0.51 \\ &= -1048 + 663.552 + 387.283 - 0.51 \\ f(x^{(4)}) &= 2.325 \end{aligned}$$

$$y(x^{(4)}) = \text{sgn}(f(x^{(4)})) = +1$$

4) a) DOKAŽI DA JE GAUSSOVA JEZGRA MERCIROVU JEZGRU

GAUSSOVA JEZGRA $\Rightarrow K(x, x') = \exp(-\gamma \|x - x'\|^2) = \exp(-\gamma (x^2 - 2xx' + x'^2)) =$
 $= \underbrace{\exp(-\gamma)}_{\text{SKALARNI}} \underbrace{\exp(x^2) \exp(-2xx') \exp(x'^2)}_{f(x) f(x')}$ $\rightarrow f \rightarrow$ bilokalna funkcija

Potrebno je pokazati da je K mercirova jezgra

$$K(x, x') = -2xx' = -\sqrt{2}x \sqrt{2}x' = -\Phi^T(x)\Phi(x') \rightarrow \text{MERCIROVA JEZGRA!}$$

b) UTJECAJ $\gamma = 1$ GAUSSOVU JEZGRU NA SLOŽENOST MODELA?

ODNOS $C_i \gamma = ?$

$\Rightarrow \gamma \uparrow \rightarrow G^2 \downarrow \rightarrow$ "NEAK" Gaussova jezgra $\downarrow \rightarrow$ Primjeri efektivne RAĐAVITI \rightarrow
 \rightarrow SKALARNI PRODUKT PRIMJERA MANJI $\rightarrow K(x, x') \rightarrow \emptyset$ (osim za $x = x'$) \rightarrow
 \rightarrow PREDNUČENOST! \rightarrow SLOŽENOST MODELA \uparrow
 $\downarrow \gamma \uparrow$ složenost \uparrow

$\rightarrow C \uparrow$ kazna \uparrow složenost \uparrow

\Rightarrow PONEŽANOST, ODNOS, $C_i \gamma = ?$

\downarrow Ako odaberemo visoku preciznost, $\gamma \uparrow$, model će postati
složniji pa trebamo pozicati regularizaciju odabirući
marg C_i , $C_i \downarrow$ ($\lambda \uparrow$)

C) $\delta=1$ MOŽEMO LI ODREDITI U KOJIM $\Phi(x)$ ĆE SE PRESURADAT X? MOŽETKO LI ODREDITI TEŽINE W? ZAŠTO?

Ne! $\Phi(x)$ definiran je samo implicitno, s obzirom da Gaussova jezgra definira $K(x, x')$

↳ S obzirom da ne možemo odrediti $\Phi(x)$ nemoguemo odrediti ni w jer su del broj:

$$w = \sum_{i=1}^n d_i y^{(i)} \Phi(x^{(i)})$$

a)

i) Primjera Gaussove ne GARANTIRATE empirisku pogr. = \emptyset na skupu za učenje.

ii) Ili NE GARANTIRATE savršenu lin. odvojivost pr. za učenje.

proston razlog

iii) Ili NE GARANTIRATE minimalnu pogrešku na ispitnom skupu

iv) Ili GARANTIRATE prelikovane povezane \rightarrow prostor razlog

(5)

a) $D = \{(x_1, 0), 1\}, \{(x_2, 1), 1\}, \{(x_3, 2), 1\}, \{(x_4, 2), 0\}, \{(x_5, 1, 1), 0\}, \{(x_6, 2), 0\}$

$k=4$

$x^{(1)} = (x_1, 1) \quad x^{(2)} = (x_2, 1) \quad \text{Uvod u klasifikaciju}$

Počinjamo euclidsku udaljenost novih p. od pr. a D, gledajući najblizu svakog i na temelju njihove klasifikacije bavimo se novim primjerom \rightarrow na temelju VECINSKE OZNAKE k nebluziti susjeda

b) $f(x) = \operatorname{argmax}_{j \in \{0, 1, 2\}} \sum \mathbb{1}\{j = y^{(i)}\} \quad d = \|x - x^{(i)}\|^2$

$x^{(1)}: d_{1,1} = 5 \quad d_{1,2} = 1 \quad d_{1,3} = 9 \quad d_{1,4} = 2 \quad d_{1,5} = 2 \quad d_{1,6} = 10$

↳ najblizi susjedi x_1, x_2, x_4, x_5 s označenom $y = [1 \ 1 \ 0 \ 0]$

Ne možemo implicitno odrediti klasifikaciju, posetili nam je veliki dodatni kriterij /vjet

$x^{(2)}: d_{2,1} = 28 \quad d_{2,2} = 20 \quad d_{2,3} = 46 \quad d_{2,4} = 27 \quad d_{2,5} = 33 \quad d_{2,6} = 59$

↳ 4-NN: x_1, x_2, x_4, x_5 s označenom $y = [1 \ 1 \ 0 \ 0]$ -1-4

b) Ponovi KLASIFIKACIJU s DEFINISKIM 4-NN PRIMJENOM INVERZNE VRAĐALJE KEGE

$f(x) = \operatorname{argmax}_{j \in \{0, 1, 2\}} \sum_{i=1}^n \mathbb{1}\{j = y^{(i)}\}$

$\mathbb{K}(x^{(i)}, x) = \frac{1}{1 + \|x - x^{(i)}\|^2}$

$f_1(x) = \operatorname{argmax} \left\{ \mathbb{K}(x^{(1)}, x_1) + \mathbb{K}(x^{(1)}, x_2), \mathbb{K}(x^{(1)}, x_4) + \mathbb{K}(x^{(1)}, x_5) \right\} =$

- $\operatorname{argmax} \left\{ (1+d_1)^{-1} + (1+d_2)^{-1}, (1+d_4)^{-1} + (1+d_5)^{-1} \right\} =$

$f_1(x) = \operatorname{argmax} \{0.67, 0.67\} \rightarrow$ Ponovo definirati veliki dodatni kriterij

$f_2(x) = \operatorname{argmax} \{0.085, 0.065\} \rightarrow f_2(x^{(2)}) = 1$



c) POGR. UC / GEN KAO FUNKCIJA OD K

!!! $K=1 \quad E_{UC} = \emptyset !$

$K \uparrow \quad E_{UC} \uparrow !$

s $K=N$ se gubi mogućnost klasifikacije u bilo kojoj klasi osim najbajnije

d) POGR. UC / GEN ZA $k=1$ i $k=3$
KAO FUNKCIJE OD N



(b) ODNOŠI IZMEĐU i) SLOŽENOSTI MODELA, ii) BROJ PARAMETARA MODELA, iii) DIM. UL. PROSTORA iv) BROJ PRIMERA (ZASEBNO PARAM. I., NEPARAH.)

PARAMETARSKI : - Broj parametara modela (w) raste s dimenzijom ulaznog prostora (N) (odnosno s dimenzijom prostora značajki), ali, broj parametara modela ne ovisi o broju primjera za učenje N !
PARAMETRI w -ovi
 $w = [w_0, w_1, \dots, w_n]$
 n -parametara
= dimenzija

- Složenost modela raste s povećanjem broja parametara, a ne ovisi o broju primjera.

NEPARAMETARSKI : - Broj parametara modela raste s brojem primjera za učenje N , a ne ovisi o dimenziji ulaznog prostora N .
- Složenost modela (ovisno o) raste s brojem primjera za učenje, a ne ovisi o dimenziji ulaznog prostora.